

Document technique

Roger SOLORZANO CANALES

Septiembre 2024

Introduction

Cet exercice portait sur une introduction opérationnelle aux requêtes de langage SQL. Il se composait de 6 étapes pratiques de travail, que j'ai réussies à bien développer.

Dans ce document, j'aborde les étapes suivantes :

- L'Exploration des données.
- Le schéma relationnel
- Le code SQL pour générer les tables
- La base de données chargée sur un SGBS.

Le but de l'exercice était de se mettre dans la peau d'un data analyst qui doit **aider une entreprise de l'assurance à mieux accompagner ses clients en analysant le marché des assurances habitation.**

Pour ce faire, les ressources reçues ont été les fichiers SCV « contrat » et « region », téléchargeables directement depuis la plateforme Openclassrooms.

Pour le développement des étapes suivantes j'ai aussi téléchargé le fichier XLSX « Dictionnaire des données », avec une initiation à manier d'exemple du format du dictionnaire. Et le fichier JPG « Schéma étudiant » qui montrait une partie du schéma à établir.

L'Exploration des données

Pour commencer l'exploration des données, j'ai transformé la visualisation du format CSV au format des colonnes, en utilisant l'outil Excel : option « Convertir », disponible dans l'onglet Données.

Cette transformation m'a permit d'identifier dans chaque fichier :

Contrat : 14 colonnes, et 30336 enregistrements. Voici une capture d'ecran.

	A	B	C	D	E	F	G	H	I	J	K	L	M	N
1	Contrat_ID	No_voie	B.T.Q	Type_de_voie	Voie	Code_dep_code_commune	Code_postal	Surface	Type_local	Occupation	Type_contrat	Formule	Valeur_declaree_biens	Prix_cotisation_mensuel
2	100601	190	A	RUE	CENTRALE	1350	1370	50	Appartement	Locataire	Residence prin	Integral	0-25000	25
3	100602	347		RUE	DU CHATEAU	1103	1170	48	Appartement	Locataire	Residence prin	Classiqui	0-25000	30
4	100603	58		AV	DU MONT BL	1143	1220	131	Appartement	Proprietaire	Residence prin	Integral	25000-50000	57
5	100604	140		RUE	DE L'ABBE JO	1288	1630	109	Maison	Locataire	Residence prin	Integral	25000-50000	43
6	100605	39		RUE	BUFFON	1033	1200	109	Appartement	Locataire	Residence prin	Classiqui	0-25000	33
7	100606	8		RUE	DE GENEVE	1354	1630	53	Appartement	Proprietaire	Residence prin	Classiqui	0-25000	19
8	100607	2		RUE	DU RECULET	1354	1630	59	Appartement	Proprietaire	Residence prin	Integral	0-25000	15
9	100608	1403		RUE	JEAN DE GIN	1143	1220	93	Maison	Proprietaire	Mise en locatio	Integral	25000-50000	34
10	100609	226		ALL	DES CAPUCIN	1354	1630	117	Maison	Proprietaire	Residence prin	Classiqui	25000-50000	32
11	100610	276		RTE	DE POUAGNY	1288	1630	36	Appartement	Proprietaire	Residence prin	Integral	25000-50000	22
12	100611	79		CRS	DE VERDUN	1283	1100	138	Appartement	Proprietaire	Residence secc	Classiqui	0-25000	11
13	100612	240		RUE	DE PRE BAILL	1173	1170	45	Appartement	Locataire	Residence prin	Classiqui	0-25000	16
14	100613	3		RUE	TURENNE	1033	1200	83	Appartement	Locataire	Residence prin	Classiqui	0-25000	14
15	100614	44		ALL	DU SQUARE E	1143	1220	88	Appartement	Locataire	Residence prin	Integral	25000-50000	34
16	100615	59		RUE	ALEXANDRE I	1004	1500	165	Appartement	Locataire	Residence prin	Classiqui	25000-50000	24
17	100616	282		CHE	DES LONGES	1071	1170	42	Appartement	Proprietaire	Residence prin	Classiqui	0-25000	17
18	100617	54		GR	GRANDE RUE	1396	1150	68	Appartement	Proprietaire	Residence secc	Classiqui	0-25000	10
19	100618	1		RUE	DE GEX	1160	1210	83	Appartement	Proprietaire	Residence prin	Classiqui	0-25000	20
20	100619	17		LOT	LES JARDINS	1103	1170	30	Appartement	Proprietaire	Residence secc	Classiqui	0-25000	12
21	100620	226		RUE	DES CAPUCIN	1354	1630	117	Maison	Proprietaire	Residence prin	Classiqui	25000-50000	32

Region : 8 colonnes, et 38917 enregistrements. Voici la capture.

	A	B	C	D	E	F	G	H
1	Code_dep_code_commune	reg_code	reg_nom	aca_nom	dep_nom	com_nom_maj_court	dep_code	dep_nom_num
2	1001	84	Auvergne-Lyon	Ain	LABERGEMENT CLEMEN		1	Ain (01)
3	1002	84	Auvergne-Lyon	Ain	L ABERGEMENT DE VAR		1	Ain (01)
4	1003	84	Auvergne-Lyon	Ain	AMAREINS		1	Ain (01)
5	1004	84	Auvergne-Lyon	Ain	AMBERIEU EN BUGEY		1	Ain (01)
6	1005	84	Auvergne-Lyon	Ain	AMBERIEUX EN DOMBE		1	Ain (01)
7	1006	84	Auvergne-Lyon	Ain	AMBLEON		1	Ain (01)
8	1007	84	Auvergne-Lyon	Ain	AMBRONAY		1	Ain (01)
9	1008	84	Auvergne-Lyon	Ain	AMBUTRIX		1	Ain (01)
10	1009	84	Auvergne-Lyon	Ain	ANDERT ET CONDON		1	Ain (01)
11	1010	84	Auvergne-Lyon	Ain	ANGLEFORT		1	Ain (01)
12	1011	84	Auvergne-Lyon	Ain	APREMONT		1	Ain (01)
13	1012	84	Auvergne-Lyon	Ain	ARANC		1	Ain (01)
14	1013	84	Auvergne-Lyon	Ain	ARANDAS		1	Ain (01)
15	1014	84	Auvergne-Lyon	Ain	ARBENT		1	Ain (01)
16	1015	84	Auvergne-Lyon	Ain	ARBIEN		1	Ain (01)

Cette format m'a aussi permit d'identifier le type des enregistrements pour chaque colonnes, ainsi que les colonnes avec des champs vides.

Le travail suivante a été de consitituer le dictionnaire des données, en indiquant, pour chaque fichier SCV et chaue colonnes : le nom, le type de données, la taille, la clé et une brief description.


Voici une capture d'ecran du dictionnaire complet :

	B	C	D	E	F	G
1						
2						
3		Nom des colonnes	Type de données	Taille	Clé	Description
4		Contrat_ID	INT		Clé primaire	Id unique pour les contrats
5		No_voie	INT			Numéro dans la voie pour l'adresse du logement assuré
6		B_T_Q	CHAR	1		Indicateur éventuel de répétition pour l'adresse du logement assuré sur un caractère
7		Type_de_voie	CVARCHAR	10		Type de voie pour l'adresse du logement assuré: rue, av (Avenue), rte (Route), ...
8		Voie	CVARCHAR	100		Libellé de la voie pour l'adresse du logement assuré
9		Code_dep_code_commune	CVARCHAR		Clé secondaire	Concaténation du code département et code commune pour avoir une clé unique
10		Code_postal	CVARCHAR	5		Code postal pour l'adresse du logement assuré
11		Surface	INT			Superficie habitable du logement assuré
12		Type_local	CVARCHAR	25		Type de logement: Appartement ou Maison
13		Occupation	CVARCHAR	25		Type de relation de possession de l'assuré avec le logement: Propriétaire ou Locataire
14		Type_contrat	CVARCHAR	25		Categorie du contrat d'assurance selon le temps d'occupation ou le type d'occupation:
15		Formule	CVARCHAR	25		Categorie du service élu par l'assuré pour son contrat: Classique ou Integral
16		Valeur_declaree_biens	CVARCHAR	25		Tranche correspondant au total du valeurs des biens présents dans le logement
17		Prix_cotisation_mensuel	INT			Montant mensuel à régler selon les caractéristiques du contrat et du logement
18		Code_dep_code_commune	CVARCHAR		Clé primaire	Concaténation du code département et code commune pour avoir une clé unique
19		reg_code	INT			Code unique de la région
20		reg_nom	CVARCHAR			Nom de la région
21		aca_nom	CVARCHAR			Nom de l'academie
22		dep_nom	CVARCHAR			Nom du departement
23		com_nom_maj_court	CVARCHAR			Nom de la commune
24		dep_code	INT			Code unique du departement
25		dep_nom_num	CVARCHAR			Concaténation du nom du departement et le code du département

Le schéma relationnel

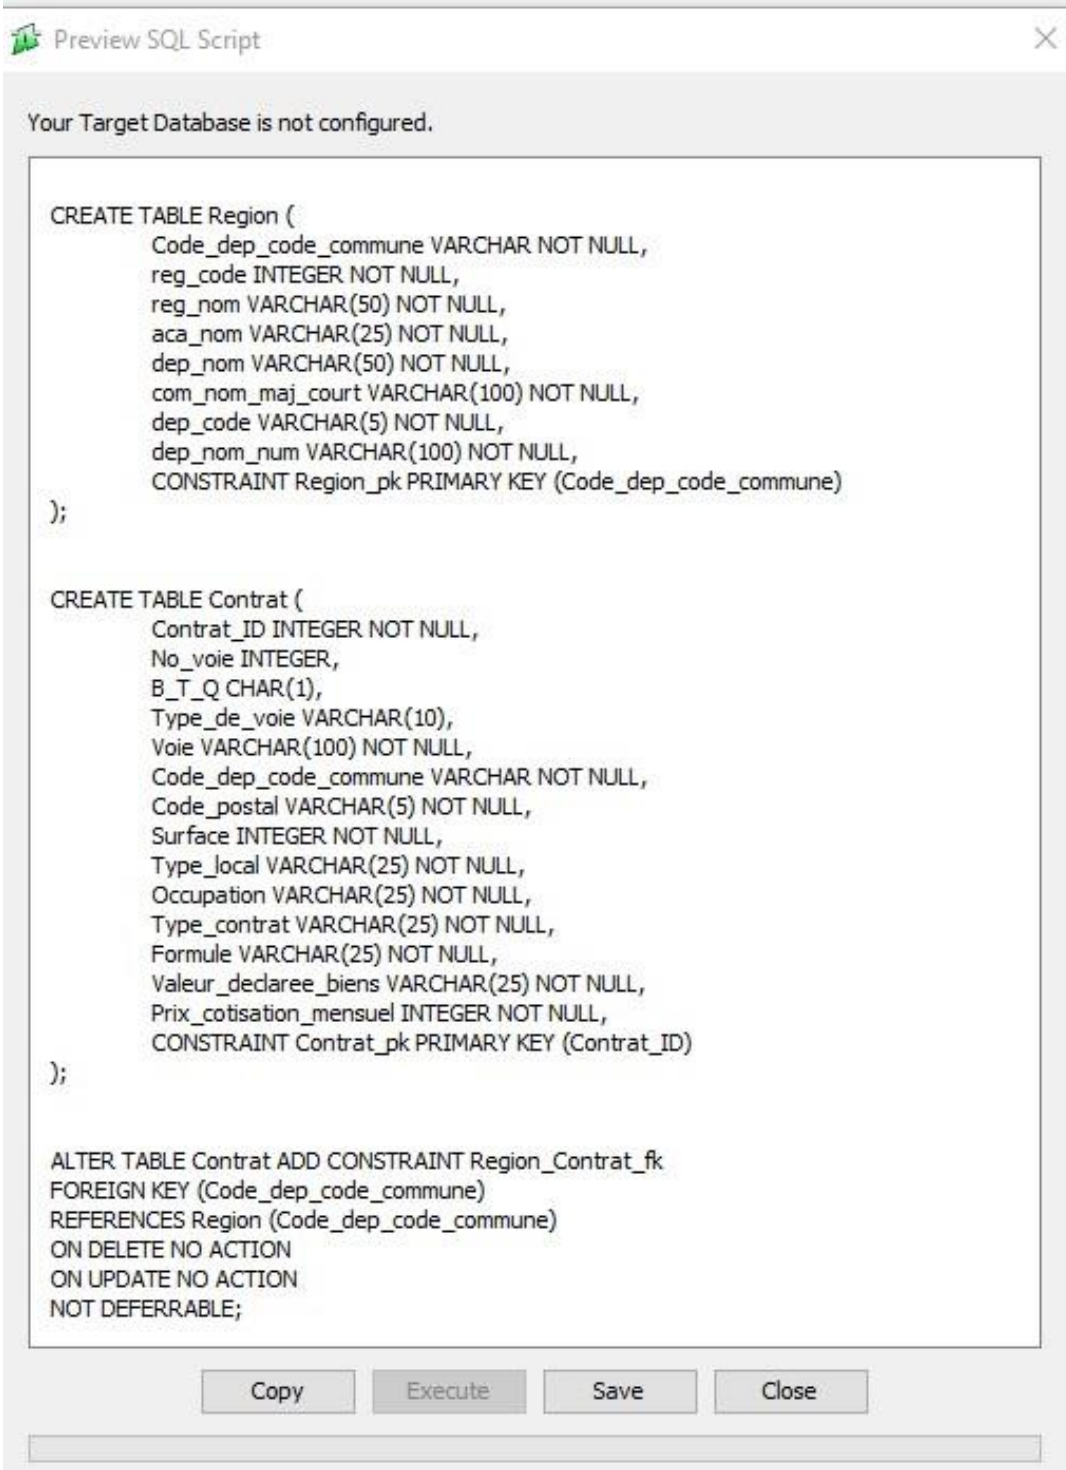
Dans l'étape suivante, j'ai téléchargé le programme SQL Power Architect, et en suivant une video tutoriel j'ai appris à établir le schéma relationnel pour constituer la base de données comprenant les deux sources : contrat et région.

Voici l'image de le schéma resultant, dans le logiciel :



Le code SQL pour générer les tables

Grace à SQL Power Architect j'ai rapidement obtenu le code SQL pour générer les deux tables qui constitueront la BDD du projet. Avec un clic sur le bouton « SQL », dans le logiciel, j'ai obtenu en format texte le code qui se montre à continuation :



```
CREATE TABLE Region (  
    Code_dep_code_commune VARCHAR NOT NULL,  
    reg_code INTEGER NOT NULL,  
    reg_nom VARCHAR(50) NOT NULL,  
    aca_nom VARCHAR(25) NOT NULL,  
    dep_nom VARCHAR(50) NOT NULL,  
    com_nom_maj_court VARCHAR(100) NOT NULL,  
    dep_code VARCHAR(5) NOT NULL,  
    dep_nom_num VARCHAR(100) NOT NULL,  
    CONSTRAINT Region_pk PRIMARY KEY (Code_dep_code_commune)  
);  
  
CREATE TABLE Contrat (  
    Contrat_ID INTEGER NOT NULL,  
    No_voie INTEGER,  
    B_T_Q CHAR(1),  
    Type_de_voie VARCHAR(10),  
    Voie VARCHAR(100) NOT NULL,  
    Code_dep_code_commune VARCHAR NOT NULL,  
    Code_postal VARCHAR(5) NOT NULL,  
    Surface INTEGER NOT NULL,  
    Type_local VARCHAR(25) NOT NULL,  
    Occupation VARCHAR(25) NOT NULL,  
    Type_contrat VARCHAR(25) NOT NULL,  
    Formule VARCHAR(25) NOT NULL,  
    Valeur_declaree_biens VARCHAR(25) NOT NULL,  
    Prix_cotisation_mensuel INTEGER NOT NULL,  
    CONSTRAINT Contrat_pk PRIMARY KEY (Contrat_ID)  
);  
  
ALTER TABLE Contrat ADD CONSTRAINT Region_Contrat_fk  
FOREIGN KEY (Code_dep_code_commune)  
REFERENCES Region (Code_dep_code_commune)  
ON DELETE NO ACTION  
ON UPDATE NO ACTION  
NOT DEFERRABLE;
```


La base de données chargée sur un SGBS

Pour construire et exploiter la base de données, j'ai chiosé et téléchargé l'outil PostgreSQL.

D'abord, j'ai créé la base de données « oc3p ». Pour ce faire, j'ai utilisé le code :

```
CREATE DATABASE nom;
```

A continuation, j'ai utilisé le code obtenu dans SQL Power Architect pour créer les deux tables de ma BDD. Voici un aperçu du résultat :

```
Select SQL Shell (psql)
WARNING: Console code page (850) differs from Windows code page (1252)
        8-bit characters might not work correctly. See psql reference
        page "Notes for Windows users" for details.
Type "help" for help.
postgres=# \d contrat
               Table "public.contrat"
   Column   |      Type      | Collation | Nullable | Default
-----|-----|-----|-----|-----
 contrat_id | integer         |           | not null |
 no_voie    | integer         |           |          |
 b_t_q     | character(1)    |           |          |
 type_de_voie | character varying(10) |         |          |
 voie      | character varying(100) |         | not null |
 code_dep_code_commune | character varying |         | not null |
 code_postal | character varying(5) |         | not null |
 surface    | integer         |           | not null |
 type_local | character varying(25) |         | not null |
 occupation | character varying(25) |         | not null |
 type_contrat | character varying(25) |         | not null |
 formule    | character varying(25) |         | not null |
 valeur_declaree_biens | character varying(25) |         | not null |
 prix_cotisation_mensuel | integer         |           | not null |
Indexes:
    "contrat_pk" PRIMARY KEY, btree (contrat_id)
Foreign-key constraints:
    "region_contrat_fk" FOREIGN KEY (code_dep_code_commune) REFERENCES region(code_dep_code_commune)
```

```
SQL Shell (psql)
postgres=# \d region
               Table "public.region"
   Column   |      Type      | Collation | Nullable | Default
-----|-----|-----|-----|-----
 code_dep_code_commune | character varying |         | not null |
 reg_code    | character varying(50) |         | not null |
 reg_nom     | character varying(50) |         | not null |
 aca_nom     | character varying(25) |         | not null |
 dep_nom     | character varying(50) |         | not null |
 com_nom_maj_court | character varying(100) |         | not null |
 dep_code    | character varying(5) |         | not null |
 dep_nom_num | character varying(100) |         | not null |
Indexes:
    "region_pk" PRIMARY KEY, btree (code_dep_code_commune)
Referenced by:
    TABLE "contrat" CONSTRAINT "region_contrat_fk" FOREIGN KEY (code_dep_code_commune) REFERENCES region(code_dep_code_commune)

postgres=#
```

La base de données chargée sur un SGBS

Pour le chargement des données, j'ai eu plusieurs erreurs à surmonter.

Premièrement, je ne pouvais pas le charger à cause d'une situation des droits, car je recevais l'erreur « *Permission denied* ». Avec un peu de recherche, j'ai trouvé comme solution changer l'emplacement de mes fichiers vers un dossier public de mon PC.

COPY contrat FROM 'C:\Users\Public\contrat.csv' DELIMITER ';' CSV HEADER;

Deuxièmement, j'ai pu charger les données pour la table « region », cependant, je recevais une erreur au moment de charger les données dans la table région.

Cette ainsi que j'ai trouvé comme cause de cette erreur des incompatibilités présents dans les colonnes « Code_dep_code_commune » de chaque fichier. C'est cette colonne qui a été utilisé pour établir la liaison entre les deux tables. Elle était la Clé Primaire dans Région, et Clé étranger dans Contrat.

Etant donné que le fichier region.csv provenait d'une source officielle, le site data.gouv.fr, j'ai obtenu les données officielles et comparé avec les données du fichier. C'est alors que j'ai identifié une différence pour plusieurs codes du département La Réunion, où un chiffre de plus avait été ajouté.

[illegible]


Troisièmement, j'ai pu identifier que dans le fichier contrat.csv, plusieurs lignes correspondantes aussi à des communes dans la région La Réunion, avaient le même enregistrement du code postal dans la colonne clé de code commune. En utilisant la fonction « recherchev » dans Excel, j'ai pu trouver les valeurs différentes entre les colonnes clés des deux fichiers.

Mise en page		Formules		Données		Révision		Affichage		Développeur		Aide	
fx		=RECHERCHEV(F2:F30336,Region1A1:H38917,1,FAUX)											
D	E	F	G	H	I	J	K	L	M	N	O	P	
de_voie	Voie	Code_dep_cc	Code_postal	Surface	Type_local	Occupation	Type_contrat	Formule	Valeur_declé	Prix_cotisation_mensuel			
E	CENTRALE	1350	1370	50	Appartement	Locataire	Residence pr	Integral	0-25000	25		1350	
E	DU CHATEAU	1103	1170	48	Appartement	Locataire	Residence pr	Classique	0-25000	30		1103	
E	DU MONT BL	1143	1220	131	Appartement	Proprietaire	Residence pr	Integral	25000-50000	57		1143	
E	DE L'ABBE JO	1288	1630	109	Maison	Locataire	Residence pr	Integral	25000-50000	43		1288	
E	BUFFON	1033	1200	109	Appartement	Locataire	Residence pr	Classique	0-25000	33		1033	
E	DE GENEVE	1354	1630	53	Appartement	Proprietaire	Residence pr	Classique	0-25000	19		1354	
E	DU RECULET	1354	1630	59	Appartement	Proprietaire	Residence pr	Integral	0-25000	15		1354	
E	JEAN DE GIN	1143	1220	93	Maison	Proprietaire	Mise en loca	Integral	25000-50000	34		1143	
E	DES CAPUCIN	1354	1630	117	Maison	Proprietaire	Residence pr	Classique	25000-50000	32		1354	
E	DE POUGIN	1288	1630	36	Appartement	Proprietaire	Residence pr	Integral	25000-50000	22		1288	
S	DE VERDUN	1283	1100	138	Appartement	Proprietaire	Residence se	Classique	0-25000	11		1283	
E	DE PRE BAILL	1173	1170	45	Appartement	Locataire	Residence pr	Classique	0-25000	16		1173	
E	TURENNE	1033	1200	83	Appartement	Locataire	Residence pr	Classique	0-25000	14		1033	
E	DU SQUARE F	1143	1220	88	Appartement	Locataire	Residence pr	Integral	25000-50000	34		1143	
E	ALEXANDRE I	1004	1500	165	Appartement	Locataire	Residence pr	Classique	25000-50000	24		1004	
E	DES LONGES	1071	1170	42	Appartement	Proprietaire	Residence pr	Classique	0-25000	17		1071	
E	GRANDE RUE	1396	1150	68	Appartement	Proprietaire	Residence se	Classique	0-25000	10		1396	
E	DE GEX	1160	1210	83	Appartement	Proprietaire	Residence pr	Classique	0-25000	20		1160	
T	LES JARDINS	1103	1170	30	Appartement	Proprietaire	Residence se	Classique	0-25000	12		1103	
E	DES CARPIER	1399	1170	25	Appartement	Locataire	Residence pr	Integral	0-25000	11		1399	
E	CHARLES DE	1202	1150	53	Appartement	Locataire	Residence pr	Integral	0-25000	12		1202	
E	DES USINIER	1173	1170	46	Appartement	Proprietaire	Residence se	Classique	0-25000	12		1173	
E	DU JURA	1354	1630	84	Appartement	Proprietaire	Residence pr	Classique	0-25000	20		1354	
E	MARCEL DEM	1004	1500	68	Appartement	Locataire	Residence pr	Integral	0-25000	13		1004	
E	DE CHARIGN	1034	1300	62	Appartement	Proprietaire	Residence pr	Classique	0-25000	11		1034	
E	DE BRETAGNY	1281	1210	113	Maison	Proprietaire	Residence pr	Integral	25000-50000	32		1281	
E	DES HETRES	1354	1630	132	Appartement	Proprietaire	Residence pr	Classique	25000-50000	30		1354	
E	DE MEYRIN	1160	1210	64	Appartement	Proprietaire	Residence pr	Integral	0-25000	15		1160	
E	DE LA MAIRIE	1138	1350	36	Appartement	Proprietaire	Residence pr	Integral	0-25000	12		1138	
E	GRANDE RUE	1202	1150	70	Appartement	Locataire	Residence pr	Classique	0-25000	14		1202	
E	DE LA BIENNI	1148	1590	200	Appartement	Proprietaire	Residence se	Classique	0-25000	13		1148	
E	REINE CLOTIL	1004	1500	55	Appartement	Proprietaire	Residence pr	Integral	0-25000	9		1004	
E	REINE CLOTIL	1004	1500	55	Appartement	Proprietaire	Residence pr	Integral	0-25000	9		1004	

[illegible]

Utilisant le code postal et l'adresse dans le fichier contrat.csv, j'ai pu trouver dans des sources officielles le code commune correcte.

Comme par exemple :



J'ai alors procédé au nettoyage des données :

J'ai corrigé le code commune pour les enregistrement avec un chiffre de plus dans région.csv.

J'ai changé le code commune pour les enregistrement où le code postale avait été reproduit dans cette champ, dans le fichier region.csv.

Finalement, j'ai pu charger les données pour les deux tables, avec le nombre des ligne correctes.

Voici le résultat attendu :

```
SQL Shell (psql)
postgres=# SELECT count (*) FROM region;
count
-----
38916
(1 row)

postgres=# SELECT count (*) FROM contrat;
count
-----
30335
(1 row)

postgres=#
```